

APV - TP5 : Naïve Bayes Classifier Hugo Huank

Exercice 1

On a $h_0(x) = \arg \min_{c_j \in Y} \sum_{i=1}^m L_j(c_i) p(c_i|x)$

et on sait que $L_j(c_j) = 0$ et $L_j(c_i) = 1$

si $i \neq j$.

Avec la formule de Bayes : $P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$

on peut effectuer le développement suivant :

$$h_0(x) = \arg \min_{c_j \in Y} \sum_{i=1}^m L_j(c_i) p(c_i|x)$$

$$= \arg \min_{c_j \in Y} \left(\sum_{i=1}^m p(c_i|x) \right) - p(c_j|x)$$

$$= \arg \min_{c_j \in Y} \left(\sum_{i=1}^m \frac{p(x|c_i) \cdot p(c_i)}{p(x)} \right) - p(c_j|x)$$

$$= \arg \min_{c_j \in Y} \frac{1}{p(x)} \left(\sum_{i=1}^m p(x | c_i) p(c_i) \right) - p(c_j | x)$$

$$= \arg \min_{c_j \in Y} \frac{1}{p(x)} \left(\sum_{i=1}^m p(x \wedge c_i) \right) - p(c_j | x)$$

$$= \arg \min_{c_j \in Y} \frac{1}{p(x)} p(x) - p(c_j | x)$$

$$= \arg \min_{c_j \in Y} 1 - p(c_j | x)$$

$$= \arg \max_{c_j \in Y} p(c_j | x)$$

$$= \arg \max_{c_j \in Y} \frac{p(x | c_j) p(c_j)}{p(x)}$$

$$= \underline{\underline{\arg \max_{c_j \in Y} p(x | c_j) p(c_j)}}$$

Exercice 2

On a le modèle suivant :

$$h_{\theta}(x) = \arg \max_{c_j \in Y} \prod_{i=1}^k \mu(x_i | c_j) \mu(c_j)$$

À l'aide des données d'entraînement on peut calculer les probabilités empiriques suivantes,

pour C_V et C_S les classes respectives des iris Versicolores et Setosa.

$$\mu(C_V) = 6/12 = \frac{1}{2}$$

$$\mu(C_S) = 6/12 = \frac{1}{2}$$

On calcule maintenant les probabilités empiriques pour chaque attribut de notre observation et pour chaque classe.

Veronicares :

$$p(\text{Sépale Vert} | C_v) = \frac{2}{6} = \frac{1}{3}$$

$$p(\text{Sépale Anordie} | C_v) = \frac{1}{6}$$

$$p(\text{Pétale Jaune} | C_v) = \frac{2}{6} = \frac{1}{3}$$

$$p(\text{Pétale Petite} | C_v) = \frac{1}{6}$$

Sesera :

$$p(\text{Sépale Vert} | C_s) = \frac{2}{6} = \frac{1}{3}$$

$$p(\text{Sépale Anordie} | C_s) = \frac{4}{6} = \frac{2}{3}$$

$$p(\text{Pétale Jaune} | C_s) = \frac{4}{6} = \frac{2}{3}$$

$$p(\text{Petite Petite} | C_5) = \frac{4}{6} = \frac{2}{3}$$

On a donc :

$$\prod_{i=1}^k p(x_i | C_v) p(C_v) = \frac{1}{3} \cdot \frac{1}{6} \cdot \frac{1}{3} \cdot \frac{1}{6} \cdot \frac{1}{2} \approx 0.00154$$

$$\prod_{i=1}^k p(x_i | C_5) p(C_5) = \frac{1}{3} \cdot \frac{2}{3} \cdot \frac{2}{3} \cdot \frac{2}{3} \cdot \frac{1}{2} \approx \underline{\underline{0.0494}}$$

$$\text{On a donc } \max_{C_j \in Y} \prod_{i=1}^k p(x_i | C_j) p(C_j) = C_5,$$

on estime alors que notre fleur est une
iris setosa.